

Machine Learning Foundation (NTU, Fall 2018) Homework #4

陳熙 R07922151

1.



2. 因為 $E_{\text{aug}}(\mathbf{w}) = E_{\text{in}}(\mathbf{w}) + \frac{\lambda}{N} \mathbf{w}^T \mathbf{w}$ ，所以有

$$\begin{aligned}\nabla E_{\text{aug}}(\mathbf{w}) &= \nabla E_{\text{in}}(\mathbf{w}) + \nabla \left(\frac{\lambda}{N} \mathbf{w}^T \mathbf{w} \right) \\ &= \nabla E_{\text{in}}(\mathbf{w}) + \frac{2\lambda}{N} \mathbf{w} \\ \mathbf{w}(t+1) &= \mathbf{w}(t) - \eta \nabla E_{\text{aug}}(\mathbf{w}(t)) \\ &= \mathbf{w}(t) - \eta \left(\nabla E_{\text{in}}(\mathbf{w}(t)) + \frac{2\lambda}{N} \mathbf{w}(t) \right) \\ &= \left(1 - \frac{2\eta\lambda}{N} \right) \mathbf{w}(t) - \eta \nabla E_{\text{in}}(\mathbf{w}(t))\end{aligned}$$

3. 對於 linear model，當用 $(-1, 0)$ 和 $(\rho, 1)$ 作為訓練樣本， $(1, 0)$ 作為 validation 樣本

時， $h_1(x) = a_1(x+1) = a_1x + a_1$ ，因為 $h_1(\rho) = 1$ ，所以， $a_1 = \frac{1}{\rho+1}$ ，

$$h_1(x) = \frac{1}{\rho+1}(x+1)，此時 e_1 = (h_1(1) - 0)^2 = \left(\frac{2}{\rho+1} \right)^2 = \frac{4}{(\rho+1)^2}。$$

當用 $(-1, 0)$ 和 $(1, 0)$ 作為訓練樣本， $(\rho, 1)$ 作為 validation 樣本時， $h_1(x) = 0$ ，

此時， $e_2 = (h_1(\rho) - 1)^2 = (0 - 1)^2 = 1$ 。

當用 $(\rho, 1)$ 和 $(1, 0)$ 作為訓練樣本， $(-1, 0)$ 作為 validation 樣本時， $h_1(x) = a_1(x - 1)$ ，

因為 $h_1(\rho) = 1$ ，所以， $a_1 = \frac{1}{\rho - 1}$ ， $h_1(x) = \frac{1}{\rho - 1}(x - 1)$ ，此時，

$$e_3 = (h_1(-1) - 0)^2 = \left(\frac{-2}{\rho - 1}\right)^2 = \frac{4}{(\rho - 1)^2}。$$

$$\text{綜上， } E_{\text{loo}} = \frac{1}{3} \sum_{n=1}^3 e_n = \frac{1}{3} \left(\frac{4}{(\rho + 1)^2} + \frac{4}{(\rho - 1)^2} + 1 \right)。$$

4. Coursera 上問題 12 中 $\mathbf{w}_{\text{reg}} = \arg \min_{\mathbf{w}} \frac{\lambda}{N} \|\mathbf{w}\|^2 + \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$ ，可以寫為

$$\begin{aligned} \mathbf{w}_{\text{reg}} &= \arg \min_{\mathbf{w}} \frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \frac{1}{N} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \\ &= \arg \min_{\mathbf{w}} \frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \frac{1}{N} (\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{y}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{y} + \mathbf{y}^T \mathbf{y}) \end{aligned}$$

令 $f(\mathbf{w}) = \frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \frac{1}{N} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y})$ ，則

$$\begin{aligned} \nabla f(\mathbf{w}) &= \nabla \frac{\lambda}{N} \mathbf{w}^T \mathbf{w} + \nabla \frac{1}{N} (\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{y}^T \mathbf{X} \mathbf{w} - \mathbf{w}^T \mathbf{X}^T \mathbf{y} + \mathbf{y}^T \mathbf{y}) \\ &= \frac{2\lambda}{N} \mathbf{w} + \frac{1}{N} (2\mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{X}^T \mathbf{y}) \\ &= \frac{2}{N} ((\lambda \mathbf{I} + \mathbf{X}^T \mathbf{X}) \mathbf{w} - \mathbf{X}^T \mathbf{y}) \\ &= \frac{2}{N} \left(\left(\lambda + \sum_{t=1}^N \|\mathbf{x}(t)\|^2 \right) \mathbf{w} - \sum_{t=1}^N y(t) \mathbf{x}(t) \right) \\ &= \frac{2}{N} \left(\lambda \mathbf{w} + \sum_{t=1}^N (\|\mathbf{x}(t)\|^2 \mathbf{w} - y(t) \mathbf{x}(t)) \right) \\ &= \frac{1}{N} \sum_{t=1}^N \left(\frac{2\lambda}{N} \mathbf{w} + 2(\|\mathbf{x}(t)\|^2 \mathbf{w} - y(t) \mathbf{x}(t)) \right) \end{aligned}$$

且 $\nabla^2 f(\mathbf{w}) = \frac{2}{N} (\lambda \mathbf{I} + \mathbf{X}^T \mathbf{X}) \succ 0$ 。

SGD 的 update rule 為：

$$\begin{aligned}
\mathbf{w}(t+1) &= \mathbf{w}(t) - \eta \nabla_{\mathbf{w}} f(\mathbf{w}(t)) \\
&= \mathbf{w}(t) - \eta \left(\frac{2\lambda}{N} \mathbf{w} + 2 \left(\|\mathbf{x}(t)\|^2 \mathbf{w} - y(t) \mathbf{x}(t) \right) \right) \\
&= \left(1 - \frac{2\eta\lambda}{N} \right) \mathbf{w}(t) - 2\eta \left(\|\mathbf{x}(t)\|^2 \mathbf{w}(t) - y(t) \mathbf{x}(t) \right)
\end{aligned}$$

Coursera 上問題 3 的 update rule 為 $\mathbf{w}(t+1) = \left(1 - \frac{2\eta\lambda}{N} \right) \mathbf{w}(t) - \eta \nabla E_{\text{in}}(\mathbf{w}(t))$,

當 $E_{\text{in}}(\mathbf{w}(t)) = \left(\mathbf{w}(t)^T \mathbf{x}(t) - y(t) \right)^2$ 時, $\nabla E_{\text{in}}(\mathbf{w}(t)) = 2 \left(\|\mathbf{x}(t)\|^2 \mathbf{w}(t) - y(t) \mathbf{x}(t) \right)$,

$\mathbf{w}(t+1) = \left(1 - \frac{2\eta\lambda}{N} \right) \mathbf{w}(t) - 2\eta \left(\|\mathbf{x}(t)\|^2 \mathbf{w}(t) - y(t) \mathbf{x}(t) \right)$ 此時兩個問題的 update

rule 相同。說明用 SGD 加 virtual examples 的方法和 regularization 的方法實現的效果相同。

5. 根據題意，因為 x 在 $[0, 2\pi]$ 均勻分佈，square error 為

$$\begin{aligned}
E(w) &= \int_0^{2\pi} (\sin ax - wx)^2 dx \\
&= \int_0^{2\pi} (\sin ax)^2 dx + \int_0^{2\pi} (wx)^2 dx - 2 \int_0^{2\pi} wx \sin ax dx
\end{aligned}$$

令 $I_1 = \int_0^{2\pi} (\sin ax)^2 dx$, $I_2 = \int_0^{2\pi} (wx)^2 dx$, $I_3 = 2 \int_0^{2\pi} wx \sin ax dx$, 則

$$I_1 = \int_0^{2\pi} \left(\frac{1}{2} - \frac{1}{2} \cos 2ax \right) dx = \pi - \frac{1}{2} \times \frac{1}{2a} [\sin 2ax]_{x=0}^{2\pi} = \pi - \frac{\sin 4a\pi}{4a}$$

$$I_2 = w^2 \int_0^{2\pi} x^2 dx = \frac{w^2}{3} [x^3]_{x=0}^{2\pi} = \frac{8\pi^3 w^2}{3}$$

$$\begin{aligned}
I_3 &= 2w \int_0^{2\pi} x \sin ax dx \\
&= -\frac{2w}{a} \int_0^{2\pi} x d(\cos ax) \\
&= -\frac{2w}{a} \left([x \cos ax]_{x=0}^{2\pi} - \int_0^{2\pi} \cos ax dx \right) \\
&= -\frac{2w}{a} \left(2\pi \cos 2a\pi - \frac{1}{a} [\sin ax]_{x=0}^{2\pi} \right) \\
&= -\frac{2w}{a} \left(2\pi \cos 2a\pi - \frac{\sin 2a\pi}{a} \right)
\end{aligned}$$

$$E(w) = \pi - \frac{\sin 4a\pi}{4a} + \frac{8\pi^3 w^2}{3} + \frac{2w}{a} \left(2\pi \cos 2a\pi - \frac{\sin 2a\pi}{a} \right)$$

$$\text{當 } w = -\frac{\frac{2}{a} \left(2\pi \cos 2a\pi - \frac{\sin 2a\pi}{a} \right)}{2 \times \left(\frac{8\pi^3}{3} \right)} = -\frac{6\pi a \cos(2\pi a) - 3\sin(2\pi a)}{8\pi^3 a^2} \text{ 時， } E(w) \text{ 有最小}$$

$$\text{值 所以對每個 } x \text{ 的 deterministic noise 為 } \left| \sin(ax) + \frac{6\pi a \cos(2\pi a) - 3\sin(2\pi a)}{8\pi^3 a^2} x \right|。$$